Applied Statistics for Data Science

Serie 1

Bemerkungen zu dieser Serie:

- Es geht in dieser Serie darum, dass Sie die Funktionsweise von **R** kennenlernen. Es geht *nicht* darum, dass Sie jeden Befehl verstanden haben oder gar auswendig können müssen.
- Auch wird *nicht* verlangt, dass Sie jeden Schritt in der Musterlösung verstehen.
- Es geht auch nicht darum, dass Sie alle Aufgaben lösen.
- Die Bewertung mit Sternen ist nicht ganz einfach. Aufgaben mit einem Stern sind für Anfänger in **R**. Diese sollten mit Nachschauen einfach zu lösen sein.

Aufgabe 1.1

In dieser Aufgabe werden einige einfache **R**-Befehle besprochen. Schauen Sie im Zweifelsfall im Dokument **`R_Intro_en.pdf`** auf ILIAS nach.

a) Bilden Sie einen Vektor **`x`** mit den Zahlen $4, 2, 1, 3, 3, 5, 7$.

b) WählenSie mit **R** den dritten Wert aus.

c) Wählen Sie mit **R** den ersten und vierten Wert aus.

d) Bestimmen Sie die Länge des Vektors **`x`**.

e) Was macht der Befehl **`x+2`**? Stellen Sie zuerst eine Vermutung auf und führen dann den Befehl aus.

f) Was macht der Befehl **`sum(x+2)`**? Stellen Sie zuerst eine Vermutung auf und führen dann den Befehl aus.

g) Was macht der Befehl **`x <= 3`**? Stellen Sie zuerst eine Vermutung auf und führen dann den Befehl aus.

h) Was macht der Befehl **`x[x <= 3]`**? Stellen Sie zuerst eine Vermutung auf und führen dann den Befehl aus.

i) Was macht der Befehl **`sort(x)`**? Stellen Sie zuerst eine Vermutung auf und führen dann den Befehl aus.

j) Was macht der Befehl `order(x)`? Stellen Sie zuerst eine Vermutung auf und führen dann den Befehl aus. Vergleichen Sie dabei die Werte von `order(x)` mit den Werten von `x`.

k) Sie möchten den Wert des 4. Eintrages durch die Zahl 8 ersetzen. Wie machen Sie das?

Aufgabe 1.2

Gegeben sind folgende Temperaturen in Grad Fahrenheit (°F)

$$51.9, \quad 51.8, \quad 51.9, \quad 53$$

a) Bilden Sie einen Vektor `fahrenheit` mit diesen Werten.

b) Berechnen Sie diese Temperaturen in Grad Celsius (°C) um. Die Umrechnungsformel lautet

$$C = \frac{5}{9}(F - 32)$$

Bilden Sie dazu einen Vektor `celsius`.

c) Gegeben sind weitere Temperaturen

$$48, \quad 48.2, \quad 48, \quad 48.7$$

Bestimmen Sie die Differenz zu den ursprünglichen Temperaturen. Benützen Sie wieder Vektoren.

Aufgabe 1.3

Wir haben von 6 Personen die Körpergewicht (kg)

$$60,\ 72,\ 57,\ 90,\ 95,\ 72$$

und das Körpergrösse (in m)

$$1.75,\ 1.80,\ 1.65,\ 1.90,\ 1.74,\ 1.91$$

gegeben.

Nun wollen wir den Body Mass Index (BMI) berechnen. Dieser berechnet sich wie folgt

$$\text{BMI} = \frac{\text{Gewicht}}{\text{Grösse}^2}$$

a) Erzeugen Sie zwei Vektoren **weight** und **height**.

b) Berechnen Sie den BMI dieser 6 Personen gleichzeitig. Erzeugen Sie dazu einen Vektor **bmi**.

Aufgabe 1.4

Die Hilfefunktion in **R** ist leider *nicht* sehr hilfreich. Man *kann* mit beispielweise **?...** einen Befehl abfragen, zum Beispiel **?seq**. Das Resultat ist für Anfänger aber meist mehr verwirrend als helfend.

a) Ein häufig vorkommender Befehl, ist der **seq(...)**-Befehl.

Googeln Sie diesen Befehl mit den Suchworten wie **r seq examples**. Erklären Sie die Funktionsweise dieses Befehles mit den Optionen **by** und **length.out**

b) Wir haben die folgende Liste gegeben

```
x <- c(4, 10, 3, NA, NA, 1, 8)
```

Zuerst eine Bemerkung zu den Wert **NA** (not available). Diese stehen für fehlende Daten, die aus irgendeinem Grund nicht vorhanden sind. Dies kommt in Statistiken recht häufig vor.

i) Wenn wir den Mittelwert von **x** bilden (**mean(x)**), so ist das Resultat **NA**. Können Sie erklären, warum dies so ist?

ii) Wie können Sie den Mittelwert aller vorkommenden Werte bilden? Googeln Sie wieder.

iii) Wenden Sie die Befehle **sort(...)** und **order(...)** auf die Liste **x** an. Was machen diese Befehle?

In beiden kommen die Optionen **na.last = ...** und **decreasing = ...**, die man **TRUE** (oder **T**) oder **FALSE** setzen kann. Was bewirken diese Optionen.

c) Plots spielen in der Statistik eine wichtige Rolle. Der folgende Plot ist zwar sehr einfach zu erstellen, sieht aber auch etwas gar schmucklos aus.

```
z <- c(4, 2, 8, 9, 7, 5, 2, 1)

plot(z)
```

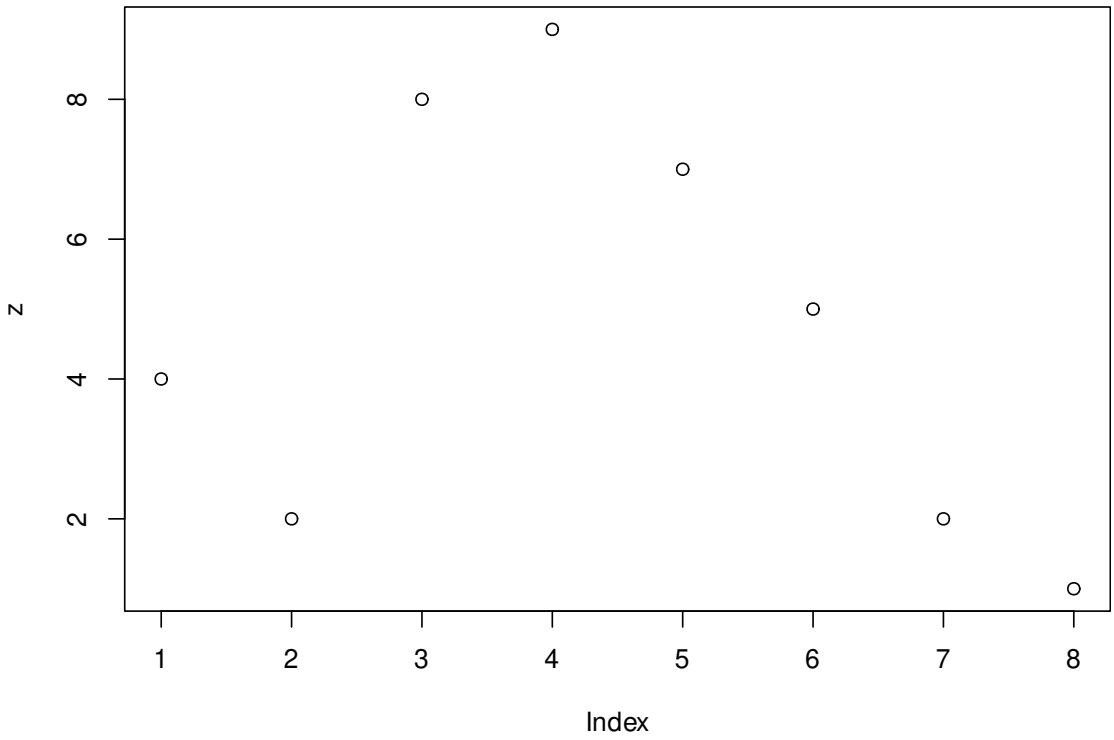

i) Ändern Sie im folgenden Befehl die Parameter der Optionen ab und beschreiben Sie, was diese Optionen bewirken (vor allem **`type`** und **`lty`**, die anderen sollten klar sein). Googeln Sie.

```
plot(z,
     type = "l",
     col = "blue",
     lty = 2,
     main = "Haupttitel",
     xlab = "Ein paar Zahlen",
     ylab = "Andere Zahlen"

)
```

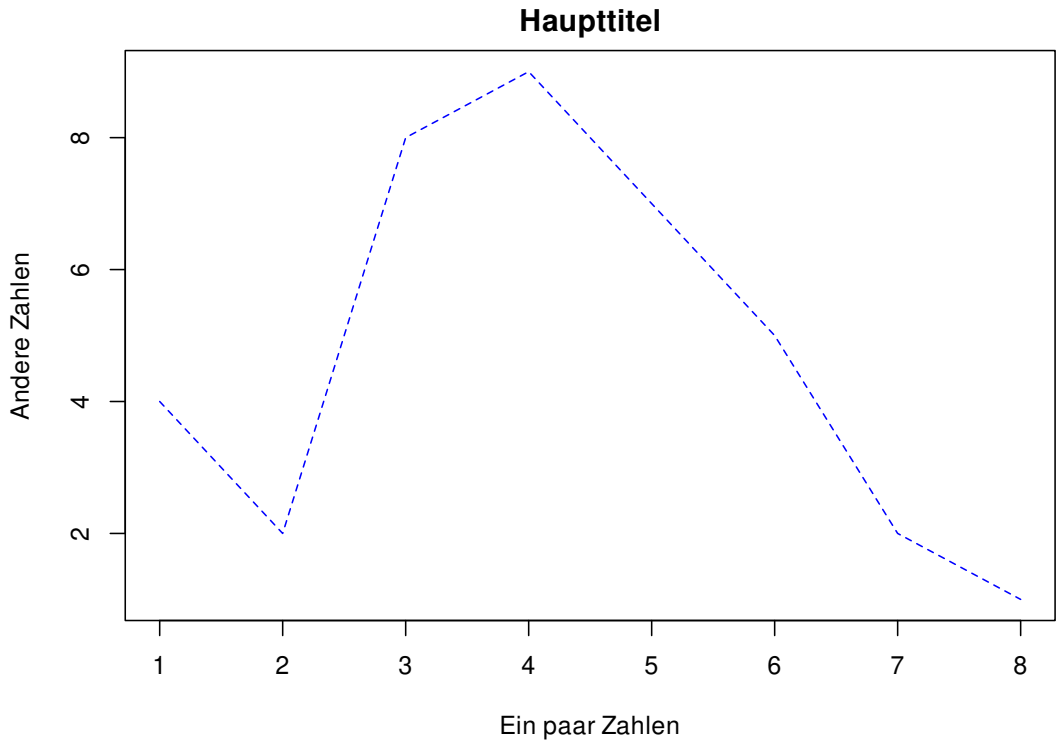

ii) Fügen Sie mit dem Befehl **`abline(...)`** drei Linien zur Graphik oben hinzu (siehe Graphik unten).

- Eine senkrechte Gerade $x = 3$, durchgezogen, grün.
- Eine waagrechte Gerade $y = 4$, gepunktet, rot.
- Eine Gerade $y = 2x + 1$, gestrichelt mit langen Strichen, braun.

```
plot(z,
     type = "l",
     col = "blue",
     lty = 2,
     main = "Haupttitel",
     xlab = "Ein paar Zahlen",
     ylab = "Andere Zahlen"

)

abline(...)
abline(...)
abline(...)
```

Wichtig ist hier, dass der **`plot()`** und **`abline()`** zusammen ausgeführt werden.

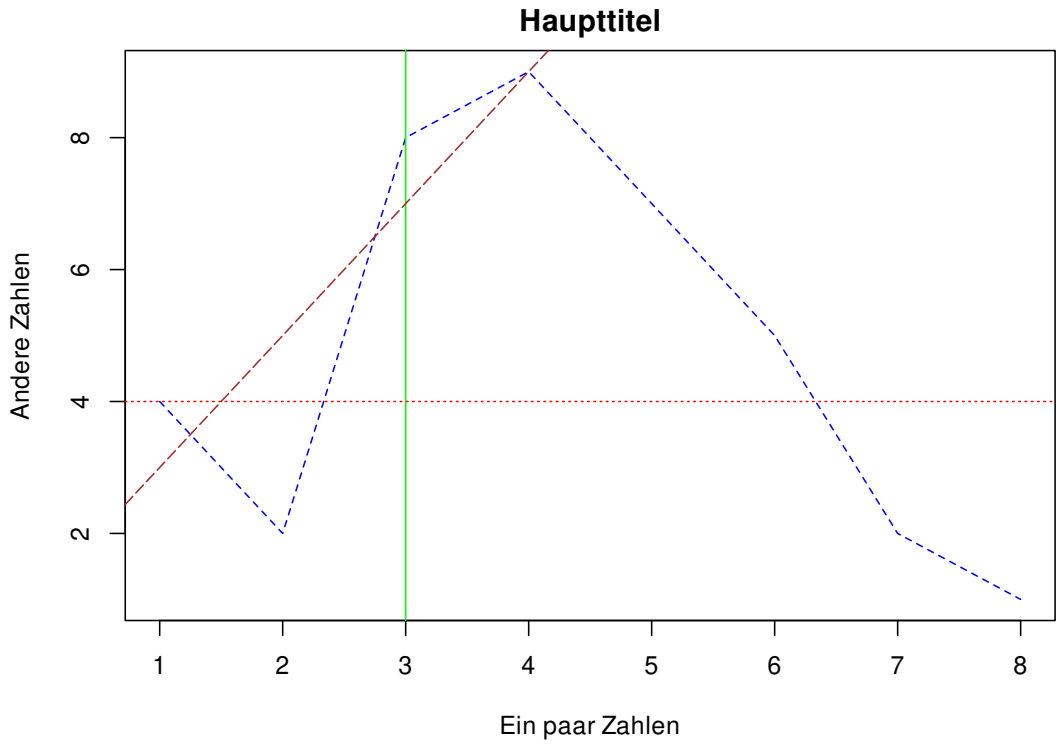

Aufgabe 1.5

Diese Aufgabe befasst sich mit dem Datensatz **weather.csv**, den wir in der Einführung kennengelernt haben.

Schauen Sie im Zweifelsfall im Dokument **`R_Intro_en.pdf`** auf ILIAS nach.

a) Laden Sie den Datensatz und speichern Sie diesen unter der Variable **`data`** ab.

b) Wählen Sie den Wert der zweiten Zeile und dritten Spalte aus.

c) Wählen Sie die 4. Zeile aus?

d) Wählen Sie die 1. und die 4. Spalte aus. Verwenden Sie dazu die Spaltennamen.

e) Speichern Sie obige Data unter dem Namen **`data1`** ab und speichern Sie dies unter dem Namen **weather2.csv**.

f) Wie können Sie herausfinden (mit **`R`** natürlich), welches der Name der 3. Spalte ist?

g) Wir möchten den Spalten **`Basel`** durch **`Genf`** ersetzen. Wie würden Sie vorgehen?

h) Wir betrachten den Befehl

```
data3 <- data[order(data[, 'Zurich']), ])
```

Dieser erzeugt

```
data3 <- data[order(data[, "Zurich"]), ]
data3

##     Luzern Basel Chur Zurich
## Feb      5     6    1      0
## Jan      2     5   -3      4
## Mar     10    11   13      8
## Apr     16    12   14     17
## May     21    23   21     20
## Jun     25    21   23     27
```

i) Wenn Sie die Tabelle anschauen, was macht dieser Befehl?

ii) Erklären Sie, warum dieser Befehl diese Wirkung hat.

Aufgabe 1.6

Das Dataframe **d.fuel** enthält die Daten verschiedener Fahrzeuge aus einer amerikanischen Untersuchung der 80er-Jahre. Jede Zeile (row) enthält die Daten eines Fahrzeuges (ein Fahrzeug entspricht einer Beobachtung).

a) Lesen Sie die auf Ilias abgelegte Datei **d.fuel.dat** ein mit dem folgenden R-Befehl:

```
d.fuel <- read.table(file = "./d.fuel.dat",
    header = T, sep = ",")
```

Das Argument **sep = ","** braucht es, weil die Kolonnen im File **d.fuel.dat** durch Kommata getrennt sind. Im File **d.fuel.dat** wurden die Zeilen durchnummeriert und daher steht in der ersten Spalte die Nummer der Zeile. Die Spalten (columns) enthalten die folgenden Variablen:

weight:	Gewicht in Pounds (1 Pound = 0.453 59 kg)
mpg:	Reichweite in Miles Per Gallon (1 gallon = 3.789 l; 1 mile = 1.6093 km)
type:	Autotyp

b) Wählen Sie nur die fünfte Zeile des Dataframe **d.fuel** aus. Welche Werte stehen in der fünften Zeile?

c) Wählen Sie nun die erste bis fünfte Beobachtung des Datensatzes aus. So lässt sich übrigens bei einem unbekannten Datensatz ein schneller Überblick über die Art des Dataframe gewinnen.

d) Zeigen Sie gleichzeitig die 1. bis 3. und die 57. bis 60. Beobachtung des Datensatzes an.

e) Berechnen Sie den Mittelwert der Reichweiten aller Autos in Miles/Gallon.

R-Hinweis:

```
mean(...)
```

f) Berechnen Sie den Mittelwert der Reichweite der Autos 7 bis 22.

g) Erzeugen Sie einen neuen Vektor **t.kml**, der alle Reichweiten in km/l, und einen Vektor **t.kg**, der alle Gewichte in kg enthält.

h) Berechnen Sie den Mittelwert der Reichweiten in km/l und denjenigen der Fahrzeuggewichte in kg.

Statistical Analysis for Data Science

Musterlösungen zu Serie 1

Lösung 1.1

a) Ein Vektor wird mit dem Befehl **`c(...)`** gebildet.

```
x <- c(4, 2, 1, 3, 3, 5, 7)
```

b)
```
x[3]

## [1] 1
```

c)
```
x[c(1, 4)]

## [1] 4 3
```

d)
```
length(x)

## [1] 7
```

e)
```
x + 2

## [1] 6 4 3 5 5 7 9
```

f)
```
sum(x + 2)

## [1] 39
```

Hier werden alle Werte in **`x+2`** aufaddiert.

g)
```
x <= 3

## [1] FALSE  TRUE  TRUE  TRUE  TRUE FALSE FALSE
```

Der Befehl erzeugt einen Vektor der Länge von **`x`**. Für alle Werte die kleiner als 3 sind, wird **`TRUE`**, für die anderen **`FALSE`**.

h)
```
x[x <= 3]

## [1] 2 1 3 3
```

Die Konstruktion **`x[...]`** wählt Elemente aus dem Vektor **`x`** aus. Die Auswahl geschieht nun mit **`x <= 3`** aus g). Es werden alle Werte ausgewählt, die den Wert **`TRUE`** haben.

i)
```
sort(x)

## [1] 1 2 3 3 4 5 7
```

Die Werte von **x** werden der Grösse nach aufsteigend geordnet.

j)
```
order(x)

## [1] 3 2 4 5 1 6 7

x

## [1] 4 2 1 3 3 5 7
```

- Der ersten Wert von **order(x)** ist 1. Der zugehörige Wert von **x** ist 1.
- Der zweite Wert von **order(x)** ist 2. Der zugehörige Wert von **x** ist 2.
- Der dritte Wert von **order(x)** ist 4. Der zugehörige Wert von **x** ist 3.
- Der vierte Wert von **order(x)** ist 5. Der zugehörige Wert von **x** ist 3.
- usw. ...

Der Befehl **order(x)** gibt also die Stellen an, *wo* sich die Werte von **x** befinden.

k)
```
x[4] <- 8
x

## [1] 4 2 1 8 3 5 7
```

Lösung

a) Vektor **fahrenheit**
```
fahrenheit <- c(51.9, 51.8, 51.9, 53)

fahrenheit

## [1] 51.9 51.8 51.9 53.0
```

b) Temperaturen in Grad Celsius (°C)
```
celsius <- 5/9 * (fahrenheit - 32)

celsius

## [1] 11.05556 11.00000 11.05556 11.66667
```

c) Weitere Temperaturen
```
fahrenheit_2 <- c(48, 48.2, 48, 48.7)

fahrenheit_3 <- fahrenheit - fahrenheit_2

fahrenheit_3
```

```
## [1] 3.9 3.6 3.9 4.3
```

Lösung

a)
```
weight <- c(60, 72, 57, 90, 95, 72)
height <- c(1.75, 1.8, 1.65, 1.9, 1.74, 1.91)
```

b) In Rerreichen wir dies durch

```
bmi <- weight/height^2

bmi

## [1] 19.59184 22.22222 20.93664 24.93075 31.37799 19.73630
```

Somit haben wir den BMI für alle 6 Personen gleichzeitig berechnet!

Lösung 1.4

a) Der Befehl **`seq(...)`** bildet eine Folge von Zahlen, die mit der ersten Zahl (**`from=...`**) beginnt und der 2. Zahl (**`to = ...`**) aufhört (sofern das geht). Die Schrittlänge wird durch **`by = ...`** angegeben.

```
seq(from = 3, to = 10, by = 2)

## [1] 3 5 7 9
```

oder in diesem Fall einfacher:

```
seq(3, 10, 2)

## [1] 3 5 7 9
```

Die Zahl 10 ist hier nicht dabei, da sie in der Aufzählung gar nicht vorkommt.

Mit der Option **`length.out`** wird angegeben, wieviele Zahlen zwischen der Anfangs- und der Endzahl gebildet werden, alle im gleichen Abstand.

```
seq(from = 3, to = 10, length.out = 10)

##  [1]  3.000000  3.777778  4.555556  5.333333  6.111111  6.888889
##  [7]  7.666667  8.444444  9.222222 10.000000
```

Oder

```
seq(3, 10, length.out = 10)

##  [1]  3.000000  3.777778  4.555556  5.333333  6.111111  6.888889
##  [7]  7.666667  8.444444  9.222222 10.000000
```

Die Optionen **by** und **length.out** *nicht* miteinander verwendet werden, da die Angaben meist widersprüchlich sind.

```
seq(from = 3, to = 10, length.out = 10, by = 2)

## Error in seq.default(from = 3, to = 10, length.out = 10, by =
2): too many arguments
```

b) i) Der **mean**-Befehl macht hier keinen Sinn, da R versucht aus *allen* Werten den Mittelwert zu ziehen und das geht mit **NA**'s natürlich nicht.

ii) Wir können allerdings mit der Option **na.rm=TRUE** (default ist **FALSE**) erreichen, dass die **NA**'s ignoriert werden (**.rm** steht für remove).

```
mean(x, na.rm = TRUE)

## [1] 5.2
```

iii) Der **sort**-Befehl ist der einfachere der beiden.

```
sort(x)

## [1]  1  3  4  8 10
```

Der sortiert die vorhandenen Zahlen aufsteigend.

Wollen wir die Sortierung aber absteigend, so verwenden wir die Option **decreasing = TRUE** (default ist **FALSE**).

```
sort(x, decreasing = TRUE)

## [1] 10  8  4  3  1
```

Die **NA**-Werte wurden allerdings ignoriert. Wollen wir die auch noch dabei haben, so wählen wir die Option **na.last = TRUE**

```
sort(x, decreasing = TRUE, na.last = TRUE)

## [1] 10  8  4  3  1 NA NA
```

Wollen wir die **NA**'s am Anfang, so setzen wir diese Option **FALSE**

```
sort(x, decreasing = TRUE, na.last = FALSE)

## [1] NA NA 10  8  4  3  1
```

Wir betrachten nun noch den **order**-Befehl.

```
order(x)

## [1] 6 3 1 7 2 4 5
```

Betrachten wir die ursprüngliche Liste

```
x

## [1]  4 10  3 NA NA  1  8
```

Hier sehen wir, dass die 6. Zahl die kleinste ist, die 3. Zahl die zweitkleinste usw. Die **NA**'s (4. und 5. Zahl) sind dabei am Schluss.

Die Optionen **decreasing = ...** und **na.last = ...** funktionieren hier gleich, wie beim **sort**-Befehl.

c) i) Die Optionen **main = "..."**, **col = "..."**, **xlab = "..."** und **ylab = "..."** dürften klar sein.

Die Option **type = "..."** gibt den Linientyp an. Siehe auch

https://www.dummies.com/programming/r/how-to-create-different-plot-types-in-r/

Die Option **lty = "..."** gibt den Linientyp für „durchgezogene" Linien vor. Siehe auch

http://www.sthda.com/english/wiki/line-types-in-r-lty

Für die Farbpalette in **R** siehe

http://www.stat.columbia.edu/~tzheng/files/Rcolor.pdf

ii) Code:

```
plot(z, type = "l", col = "blue", lty = 2, main = "Haupttitel", xlab = "
    ylab = "Andere Zahlen")

abline(v = 3, col = "green", lty = 1)
abline(h = 4, col = "red", lty = 3)
abline(a = 1, b = 2, col = "brown", lty = 5)
```

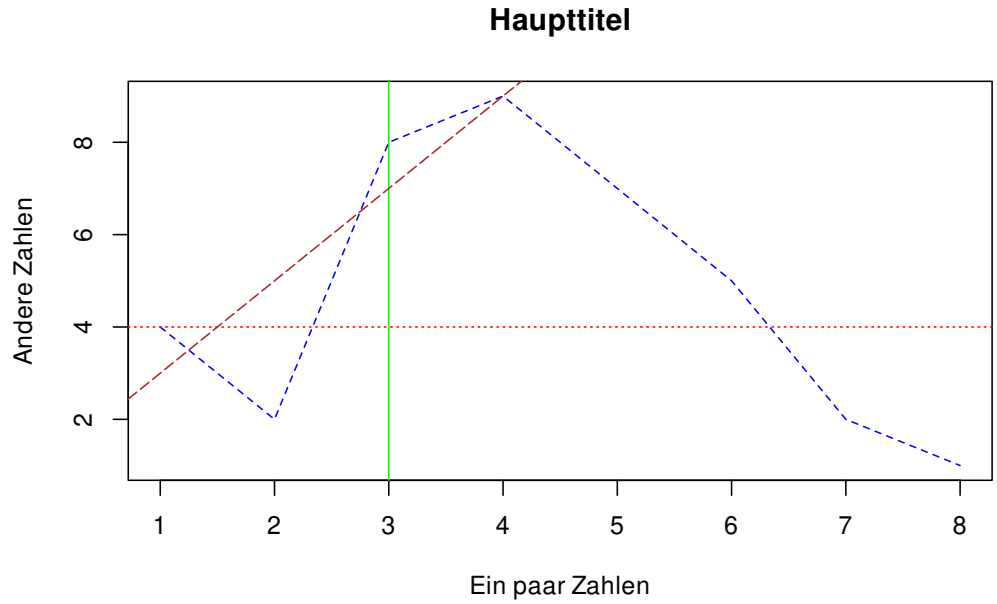

Lösung 1.5

a)
```
data <- read.csv("../../../Software_R_Python/R/weather.csv")
data
```

```
##     Luzern Basel Chur Zurich
## Jan      2     5   -3      4
## Feb      5     6    1      0
## Mar     10    11   13      8
## Apr     16    12   14     17
## May     21    23   21     20
## Jun     25    21   23     27
```

Ihr Pfad wird natürlich anders lauten. Für Windows-User: Sie müssen die \ durch / ersetzen.

b)
```
data[2, 3]
```

```
## [1] 1
```

Nochmals: Der erste Wert von **`data[..., ...]`** bezieht sich *immer* auf die Zeile und der zweite Wert auf die Spalte.

c)
```
data[4, ]
```

```
##     Luzern Basel Chur Zurich
## Apr     16    12   14     17
```

d)
```
data[, c("Luzern", "Zurich")]
```

```
##     Luzern Zurich
## Jan      2      4
## Feb      5      0
## Mar     10      8
## Apr     16     17
## May     21     20
## Jun     25     27
```

e)
```
data1 <- data[, c("Luzern", "Zurich")]
write.csv(data1, "../../../Software_R_Python/R/weather2.csv", row.names = F

data2 <- read.csv("../../../Software_R_Python/R/weather2.csv")
data2
```

```
##   Luzern Zurich
## 1      2      4
## 2      5      0
## 3     10      8
## 4     16     17
## 5     21     20
## 6     25     27
```

f)
```
colnames(data)[3]
```

```
## [1] "Chur"
```

Der Befehl **`colnames(data)`** erzeugt einen Vektor mit den Spaltennamen der Datei **`data`**. Mit **`...[3]`** wird der dritte Wert ausgewählt.

g)
```
colnames(data)[2] <- "Genf"
data
```

```
##     Luzern Genf Chur Zurich
## Jan      2    5   -3      4
## Feb      5    6    1      0
## Mar     10   11   13      8
## Apr     16   12   14     17
## May     21   23   21     20
## Jun     25   21   23     27
```

h)
```
data3 <- data[order(data[, "Zurich"]), ]
data3
```

```
##     Luzern Genf Chur Zurich
## Feb      5    6    1      0
```

```
## Jan      2    5   -3      4
## Mar     10   11   13      8
## Apr     16   12   14     17
## May     21   23   21     20
## Jun     25   21   23     27
```

i) i) Die Tabelle wird nach den Werten von Zürich austeigend geordnet.

ii) Im ersten Eintrag für **data** steht **order(data[, 'Zurich'])**. Dieser gibt die Ordnung der Spalte **Zurich** an.

```
order(data[, "Zurich"])

## [1] 2 1 3 4 5 6
```

Damit werden die Zeilen von **data** werden nach dieser Ordnung geordnet.

Lösung 1.6

a) Siehe Aufgabenstellung.

Um die Daten in Tabellenform zu sehen, tippt man den Namen des Objektes ein

```
d.fuel

##      X weight mpg    type
## 1    1   2560  33   Small
## 2    2   2345  33   Small
## 3    3   1845  37   Small
## 4    4   2260  32   Small
## 5    5   2440  32   Small
## 6    6   2285  26   Small
## 7    7   2275  33   Small
## 8    8   2350  28   Small
## 9    9   2295  25   Small
## 10 10   1900  34   Small
## 11 11   2390  29   Small
## 12 12   2075  35   Small
## 13 13   2330  26   Small
## 14 14   3320  20  Sporty
## 15 15   2885  27  Sporty
## 16 16   3310  19  Sporty
## 17 17   2695  30  Sporty
## 18 18   2170  33  Sporty
## 19 19   2710  27  Sporty
## 20 20   2775  24  Sporty
```

```
## 21 21   2840  26  Sporty
## 22 22   2485  28  Sporty
## 23 23   2670  27 Compact
## 24 24   2640  23 Compact
## 25 25   2655  26 Compact
## 26 26   3065  25 Compact
## 27 27   2750  24 Compact
## 28 28   2920  26 Compact
## 29 29   2780  24 Compact
## 30 30   2745  25 Compact
## 31 31   3110  21 Compact
## 32 32   2920  21 Compact
## 33 33   2645  23 Compact
## 34 34   2575  24 Compact
## 35 35   2935  23 Compact
## 36 36   2920  27 Compact
## 37 37   2985  23 Compact
## 38 38   3265  20  Medium
## 39 39   2880  21  Medium
## 40 40   2975  22  Medium
## 41 41   3450  22  Medium
## 42 42   3145  22  Medium
## 43 43   3190  22  Medium
## 44 44   3610  23  Medium
## 45 45   2885  23  Medium
## 46 46   3480  21  Medium
## 47 47   3200  22  Medium
## 48 48   2765  21  Medium
## 49 49   3220  21  Medium
## 50 50   3480  23  Medium
## 51 51   3325  23   Large
## 52 52   3855  18   Large
## 53 53   3850  20   Large
## 54 54   3195  18     Van
## 55 55   3735  18     Van
## 56 56   3665  18     Van
## 57 57   3735  19     Van
## 58 58   3415  20     Van
## 59 59   3185  20     Van
## 60 60   3690  19     Van
```

b) Auswählen der fünften Beobachtung:

```
d.fuel[5, ]

##   X weight mpg  type
## 5 5   2440  32 Small
```

c) Auswählen der 1. bis 5. Beobachtung:

```
d.fuel[1:5, ]

##   X weight mpg  type
## 1 1   2560  33 Small
## 2 2   2345  33 Small
## 3 3   1845  37 Small
## 4 4   2260  32 Small
## 5 5   2440  32 Small
```

Alternativ kann man sich eine Übersicht verschaffen mit Hilfe der **R**-Funktion **head(...)**

```
head(d.fuel)

##   X weight mpg  type
## 1 1   2560  33 Small
## 2 2   2345  33 Small
## 3 3   1845  37 Small
## 4 4   2260  32 Small
## 5 5   2440  32 Small
## 6 6   2285  26 Small
```

d) Auswählen der 1. bis 3. und 57. bis 60. Beobachtung:

```
d.fuel[c(1:3, 57:60), ]

##     X weight mpg  type
## 1   1   2560  33 Small
## 2   2   2345  33 Small
## 3   3   1845  37 Small
## 57 57   3735  19   Van
## 58 58   3415  20   Van
## 59 59   3185  20   Van
## 60 60   3690  19   Van
```

e) Die Werte der Reichweiten stehen in der dritten Spalte, die **mpg** heisst. Zur Berechnung des Mittelwertes gibt es verschiedene Möglichkeiten, welche sich in der Art der Datenselektion unterscheiden:

```
mean(d.fuel[, 3])

## [1] 24.58333
```

```r
mean(d.fuel[, "mpg"])

## [1] 24.58333

mean(d.fuel$mpg)

## [1] 24.58333
```

f) Auch hier gibt es wieder verschiedene Möglichkeiten. Eine davon ist:

```r
mean(d.fuel[7:22, "mpg"])

## [1] 27.75
```

g) Umrechnung der Miles Per Gallon in Kilometer pro Liter und der Pounds in Kilogramm:

```r
t.kml <- d.fuel[, "mpg"] * 1.6093/3.789
t.kg <- d.fuel[, "weight"] * 0.45359
```

h) Mittelwert der Reichweite und des Gewichtes:

```r
mean(t.kml)

## [1] 10.44127

mean(t.kg)

## [1] 1315.789
```